IJSA (2024), Vol. xx, No. yy, 1-5 **Indonesian Journal of Statistics and Its Applications**
DOI: https://doi.org/10.29244/ijsa.vxiypno Available at https://ijsa.stats.id
e-ISSN: 2599-0802

MENGUNGKAP POLA PERCERAIAN ANTAR PROVINSI DI INDONESIA TAHUN 2023 MENGGUNAKAN PENDEKATAN SPECTRAL CLUSTERING

Sandra Berliana Putri[1‡], Adinda Shabrina Putri Salsabila[1], Siti Arbaynah[1], Thariq Hambali[1], Septian Rahardiantoro[1], Cici Suaheni[1], Adhiyatma Nugraha[1]

[1]Department of Statistics, IPB University, Indonesia

[‡]corresponding author: sandraberlianaputri@apps.ipb.ac.id

Copyright © 2025, Sandra Berliana Putri, Adinda Shabrina Putri Salsabila, Siti Arbaynah, Thariq Hambali, Septian Rahardiantoro, Cici Suhaeni, dan Adhiyatma Nugraha. This is an open-access article distributed under the Creative Commons Attribution License, which permits unrestricted use, distribution, and reproduction in any medium, provided the original work is properly cited.

Abstract

Divorce remains a growing social issue in Indonesia, with over 408,000 cases recorded in 2023. The primary causes include continuous disputes (62%), economic problems (26%), abandonment (8%), domestic violence (1.27%), and other reasons (2.09%). This study aims to cluster Indonesian provinces based on patterns of divorce causative factors using the Spectral Clustering method. This approach is capable of detecting complex and non-linear structures better than traditional clustering methods like K-Means. The analysis involves constructing an affinity matrix using a Gaussian kernel, forming a symmetric normalized Laplacian matrix, and performing eigen decomposition to project the data into a new feature space. The optimal number of clusters is determined using the Silhouette Coefficient, followed by clustering with K-Means in the transformed space. The findings reveal two main clusters of provinces with differing dominant factors: one cluster driven mainly by economic problems, and the other by social issues such as abandonment. These results are expected to help policymakers design more targeted and evidence-based interventions to reduce the divorce rate across Indonesian provinces.

Keywords: divorce, gaussian kernel, K-Means, laplacian matrix, spectral clustering

1. Pendahuluan

Pernikahan tetap menjadi institusi sosial yang fundamental bagi individu yang membangun komitmen untuk kehidupan bersama dan berkelanjutan (Stanley *et al*. 2022). Akan tetapi, dinamika kehidupan modern seringkali menghadirkan tantangan bagi lembaga pernikahan yang dapat memicu konflik dan berujung pada perceraian (Amato & Patterson 2017). Idealnya, pernikahan diwarnai kebahagiaan dan kemitraan tetapi perbedaan pendapat dan perselisihan tidak terhindarkan. Pasangan diharapkan mampu menyelesaikan konflik secara konstruktif tanpa harus mengakhiri ikatan pernikahan (Gottman & Silver 2015). Perceraian, sebagai putusnya ikatan perkawinan, dapat disebabkan oleh berbagai faktor, termasuk ketidakcocokan, masalah komunikasi, atau perubahan nilai-nilai (Cherlin 2020).

Perceraian berdampak luas tidak hanya pada individu yang terlibat tetapi juga pada kesejahteraan anak-anak dan stabilitas sosial secara keseluruhan. Di Indonesia, tren perceraian menjadi perhatian serius. Pada tahun 2023, tercatat 408.347 kasus perceraian di Indonesia dengan mayoritas diajukan oleh pihak istri (cerai gugat) (BPS 2023). Kasus perceraian tersebut mengalami penurunan sebesar 20% dibandingkan tahun sebelumnya yang mencapai 516.344 kasus.

Analisis terhadap faktor-faktor penyebab perceraian di Indonesia pada tahun 2023 menunjukkan bahwa perselisihan dan pertengkaran terus-menerus menjadi penyebab utama mencakup 62% dari total kasus perceraian. Faktor ekonomi menempati urutan kedua dengan 26% dari total kasus yang menunjukkan pentingnya stabilitas ekonomi dalam mempertahankan keutuhan rumah tangga (BPS 2023). Faktor lain yang berkontribusi signifikan terhadap angka perceraian adalah meninggalkan salah satu pihak (8%), kekerasan dalam rumah tangga (KDRT) (1,27%), dan masalah terkait dengan mabuk (0,43%) (BPS 2023). Selain faktor-faktor utama tersebut, terdapat juga faktor lain seperti judi, murtad, zina, madat, dihukum penjara, poligami, cacat badan, kawin paksa, dan lain-lain yang secara kumulatif mencapai 6.783 kasus atau 1,66% (BPS 2023).

Penelitian sebelumnya telah mencoba memprediksi perceraian menggunakan metode *machine learning*. Moumen et al. (2024) menggunakan *Divorce Predictor Scale* (DPS) berdasarkan terapi pasangan Gottman untuk memprediksi perceraian di wilayah Hail, Arab Saudi. Penelitian ini melibatkan 148 peserta (116 menikah dan 32 bercerai) dan menggunakan algoritma *Artificial Neural Network* (ANN), *Naive Bayes* (NB), dan *Random Forest* (RF). Hasil penelitian menunjukkan bahwa DPS efektif dalam memprediksi perceraian menggunakan algoritma *Random Forest* dengan akurasi tertinggi sebesar 91,66% setelah seleksi fitur berbasis korelasi. Penelitian ini menegaskan bahwa DPS dapat membantu konselor keluarga dan terapis dalam formulasi kasus dan pengembangan rencana intervensi. Selain itu, Sulistiyana dan Martanto (2021) menggunakan metode *K-Means Clustering* untuk mengelompokkan kasus perceraian berdasarkan lama pernikahan dan perbedaan usia.

Penelitian-penelitian tersebut belum secara mendalam menganalisis pola hubungan antar provinsi berdasarkan faktor-faktor penyebab perceraian. Oleh karena itu, penelitian ini bertujuan mengelompokkan provinsi-provinsi di Indonesia berdasarkan faktor utama penyebab perceraian menggunakan metode *spectral clustering*. Metode ini dipilih karena kemampuannya untuk mengidentifikasi struktur klaster yang kompleks dan non-linear (Marple 2019). Dengan memahami pola perceraian di setiap provinsi, hasil penelitian ini diharapkan dapat memberikan wawasan yang lebih mendalam bagi pembuat kebijakan dalam merancang strategi penanganan perceraian yang lebih tepat sasaran dan sesuai dengan karakteristik masing-masing wilayah. Selain itu, penelitian ini diharapkan dapat menjadi dasar untuk meningkatkan program kesejahteraan keluarga dan intervensi sosial yang lebih efektif.

2. Metodologi

2.1. Data

Pada penelitian ini, data yang digunakan merupakan data sekunder dari website resmi Badan Pusat Statistik (BPS) Indonesia, yaitu www.bps.go.id. Data tersebut berupa jumlah perceraian berdasarkan faktor penyebab pada setiap provinsi di Indonesia pada tahun 2023. Adapun peubah-peubah yang digunakan disajikan pada Tabel 1.

Tabel 1: Peubah yang digunakan

No	Peubah	Keterangan	Satuan
1	X_1	Jumlah perceraian akibat mabuk	Orang
2	X_2	Jumlah perceraian akibat judi	Orang
3	X_3	Jumlah perceraian akibat meninggalkan salah satu pihak	Orang
4	X_4	Jumlah perceraian akibat kekerasan dalam rumah tangga (KDRT)	Orang
5	X_5	Jumlah perceraian akibat perselisihan dan pertengkaran	Orang
6	X_6	Jumlah perceraian akibat murtad	Orang
7	X_7	Jumlah perceraian akibat ekonomi	Orang

2.2. Spectral Clustering

Clustering adalah salah satu metode dalam menentukan pola yang terdapat pada suatu data. Pola tersebut dapat dilihat dari kemiripan sifat, karakteristik, ataupun ciri dari data (Tan *et al.* 2006). Salah satu metode dalam *clustering* adalah *spectral clustering*. Metode ini dapat menangani *cluster* dengan bentuk yang kompleks dan tidak beraturan karena kesamaan data diidentifikasi melalui ruang eigenvektor bukan ruang asli data. Metode

seperti *K-Means* dan *Gaussian Mixture Models* (GMM) sering kali gagal ketika *cluster* tidak berbentuk konveks atau berdistribusi kompleks (Ng *et al.* 2002).

Spectral clustering memanfaatkan hubungan atau konektivitas antara titik-tiitk data dalam pengelompokkan. Data direpresentasikan ke dalam bentuk graf berarah dimana simpul/*nodes* adalah titik data dan bobot sisi/*edges weight* adalah kesamaan/*similarity* antar titik data. Berdasarkan graf, matriks afinitas dapat dibentuk sehingga matriks Laplacian dapat dihitung. Eigenvektor terbesar dari matriks Laplacian digunakan untuk mengubah data kompleks ke ruang berdimensi lebih rendah. *Clustering* dilakukan pada ruang baru, yaitu ruang eigenvektor sehingga *cluster* yang sebelumnya sulit dipisahkan pada ruang asli dapat ditemukan dengan lebih mudah (Ng *et al.* 2002).

Matriks afinitas (A) adalah matriks yang merepresentasikan hubungan *similarity* antar titik data. Matriks A dapat dibentuk dengan menggunakan fungsi Gaussian karena fungsi kernel tersebut lebih baik dari kernel lain dalam menangani data yang kompleks (Trivedi *et al.* 2008).

$$A_{ij} = \exp\left(-\frac{\left|\left|s_i - s_j\right|\right|^2}{2\sigma^2}\right), jika\ i \neq\ j, A_{ii} = 0 \quad (1)$$

dimana $\left|\left|s_i - s_j\right|\right|^2$ adalah jarak Euclidean antara titik data s_i dan s_j serta σ^2 adalah parameter kecepatan nilai afinitas menurun dengan jarak. Apabila dua titik memiliki jarak yang dekat maka A_{ij} mendekati 1, sedangkan apabila dua titik jauh maka A_{ij} mendekati 0.

Matriks derajat (D) adalah matriks diagonal dimana nilai diagonal merupakan nilai total hubungan *similarity* setiap titik ke titik lainnya. Adapun rumusnya adalah sebagai berikut (Trivedi *et al.* 2008).

$$\mathrm{D_{ii}} = \Sigma_j \mathrm{A_{ij}} \quad (2)$$

sehingga $D = \begin{pmatrix} d_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & d_i \end{pmatrix}$ dimana d_i adalah jumlah elemen dalam baris i pada matriks A. D_{ii} menggambarkan seberapa terhubung titik i dengan semua titik lainnya. Apabila titik memiliki banyak tetangga yang dekat maka nilai D_{ii} akan lebih besar.

Matriks Laplacian (L) adalah matriks yang digunakan dalam memahami struktur dari graf yang direpresentasikan oleh matriks A. Matriks L terbagi menjadi dua jenis, yaitu matriks L tidak dinormalisasi dan matriks L normalisasi. Matriks L tidak dinormalisasi digunakan dalam *spectral graph partitioning* (teknik partisi graf klasik). Matriks ini bergantung pada skala data. Apabila terdapat titik yang sangat terhubung (node berderajat tinggi) maka titik tersebut dapat mendominasi hasil. Selain itu, matriks tersebut kurang stabil secara numerik terutama untuk graf dengan derajat yang beragam. Matriks L normalisasi menangani kekurangan pada matriks L tidak dinormalisasi. Matriks L normalisasi terbagi menjadi dua, yaitu matriks L simetris dan

matriks L random walk. Matriks L simetris mampu memastikan bahwa spektrum eigen lebih stabil serta hasil eigenvektor lebih seragam dan tidak bergantung pada skala matriks A sehingga hasil *clustering* lebih baik. Matriks L random walk cocok digunakan untuk analisis berbasis probabilitas dan pemodelan berbasis random walk. Namun, matriks L random walk tidak selalu memberikan hasil yang lebih baik dibanding L simetris. Oleh karena itu, pada penelitian kali ini matriks L yang digunakan adalah matriks L simetris (Trivedi *et al.* 2008).

$$L_{sym} = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \tag{3}$$

Eigenvector dihitung dari matriks L dan k *eigenvector* pertama dipilih dimana k merupakan jumlah *cluster. Eigenvalue* (v) dan *eigenvector* (λ) dari matriks L memenuhi persamaan sebagai berikut (Weiss 1999).

$$Lv = \lambda v \tag{4}$$

sehingga matriks *eigenvector* (X) dapat dibentuk.

$$X = [v_1, v_2, \dots, v_k] \tag{5}$$

Matriks X akan dinormalisasi baris untuk mengurangi efek perbedaan skala antar titik data. Hal ini dimaksudkan untuk mencegah munculnya *outlier* yang mampu mendominasi hasil. Adapun rumus yang digunakan adalah sebagai berikut (Weiss 1999).

$$Y_{ij} = \frac{X_{ij}}{\sqrt{\Sigma_j X_{ij}^2}} \tag{6}$$

Hasil dari normalisasi (Y) memiliki setiap baris yang mewakili titik dalam ruang *eigenvector*. Kemudian, pada matriks Y dilakukan *clustering* dengan menggunakan *K-Means*. Setelah data ditransformasi dalam ruang *eigenvector* yang berdimensi lebih rendah maka data menjadi lebih terstruktur dan mudah dipisahkan sehingga *K-Means* lebih efektif. Sebelum masuk ke proses *clustering K-Means*, jumlah *cluster* optimal (k) perlu ditentukan berdasarkan *Silhouette Coefficient*. Metode ini dipilih karena tidak bergantung kepada bentuk *cluster* sehingga bisa digunakan dalam data yang kompleks dan lebih mudah diinterpretasikan. *Silhouette Coefficient* mengukur seberapa baik titik data berada dalam suatu *cluster* dibandingkan *cluster* yang lainnya. Formula dari *Silhouette Coefficient* adalah sebagai berikut (Kaufman & Rousseeuw 1990 dalam Vendramin *et al.* 2008).

$$S(i) = \frac{b(i) - a(i)}{\max\big(a(i), b(i)\big)} \tag{7}$$

dimana $a(i)$ adalah rata-rata jarak titik i ke semua titik dalam *cluster* yang sama dan $b(i)$ adalah rata-rata jarak titik i ke titik-titik di *cluster* terdekat.

Proses *clustering K-Means* diawali dengan inisialisasi centroid dengan memilih sebanyak k titik sebagai $C_1, C_2, \dots, C_k$ secara acak dari baris Y. Lalu, menentukan *cluster* setiap titik berdasarkan jarak terdekat ke centroid yang dihitung dengan menggunakan

jarak Euclidean. Centroid baru setiap *cluster* diganti dengan rata-rata dari semua titik dalam *cluster*.

$$C_j = \frac{1}{S_j} \Sigma Y_j \quad (8)$$

dimana C_j adalah centroid/pusat *cluster* ke-j serta S_j adalah jumlah titik dalam *cluster* j. Proses penentuan centroid terus berulang hingga mendapatkan centroid yang tidak berubah atau perubahannya sangat kecil (konvergen) (Zhang *et al*. 2006).

2.3. Prosedur Analisis

Data penelitian dianalisis menggunakan *software* Excel dan Python dengan prosedur analisis yang dilakukan sebagai berikut.

1. *Pra-processing* dengan melakukan konversi satuan menjadi persentase, yaitu membagi jumlah perceraian tiap faktor dengan total perceraian dari tujuh faktor di setiap provinsi.
2. Eksplorasi data menggunakan korelasi.
3. Membentuk matriks Afinitas (A) dengan menghitung kemiripan antar titik data menggunakan Gaussian kernel.
4. Membangun matriks Derajat (D) yang merupakan matriks diagonal untuk menyimpan total hubungan kemiripan setiap titik ke titik lainnya.
5. Menentukan representasi spektral transformasi dengan membentuk matriks Laplacian simetris (L_{sym}).
6. Melakukan dekomposisi eigen untuk memperoleh k *eigenvector* pertama dari matriks L_{sym}.
7. Normalisasi baris pada matriks *eigenvector* (X) yang menghasilkan matriks Y.
8. Melakukan *clustering* pada matriks Y dengan algoritma *K-Means clustering* dimana jumlah k optimal ditentukan berdasarkan *Silhouette Coefficient*.

3. Hasil dan Pembahasan

3.1. *Preprocessing* Data

Tahap preprocessing dilakukan untuk menyiapkan data agar dapat dianalisis secara optimal dalam proses klasterisasi. Langkah pertama adalah mengubah skala data menjadi bentuk persentase agar seluruh faktor penyebab perceraian memiliki satuan yang seragam dan dapat dibandingkan secara langsung antarprovinsi. Data sebelum diubah satuannya ke dalam persentase dapat dilihat pada Gambar 1 dan data sesudahnya dapat dilihat pada Gambar 2.

Provinsi	Faktor Perceraian							Jumlah
	Mabuk	Judi	Meninggalkan Salah satu Pihak	Kekerasan Dalam Rumah Tangga	Perselisihan dan Pertengkaran	Murtad	Ekonomi	
Aceh	8	25	669	102	4915	12	235	**5966**
Sumatera Utara	12	121	1065	136	13709	73	465	**15581**
Sumatera Barat	1	3	859	19	6969	18	113	**7982**
...	...	...	...	...	...	...	...	**...**
Total	**1752**	**1572**	**34322**	**5174**	**251828**	**1415**	**108488**	**404551**

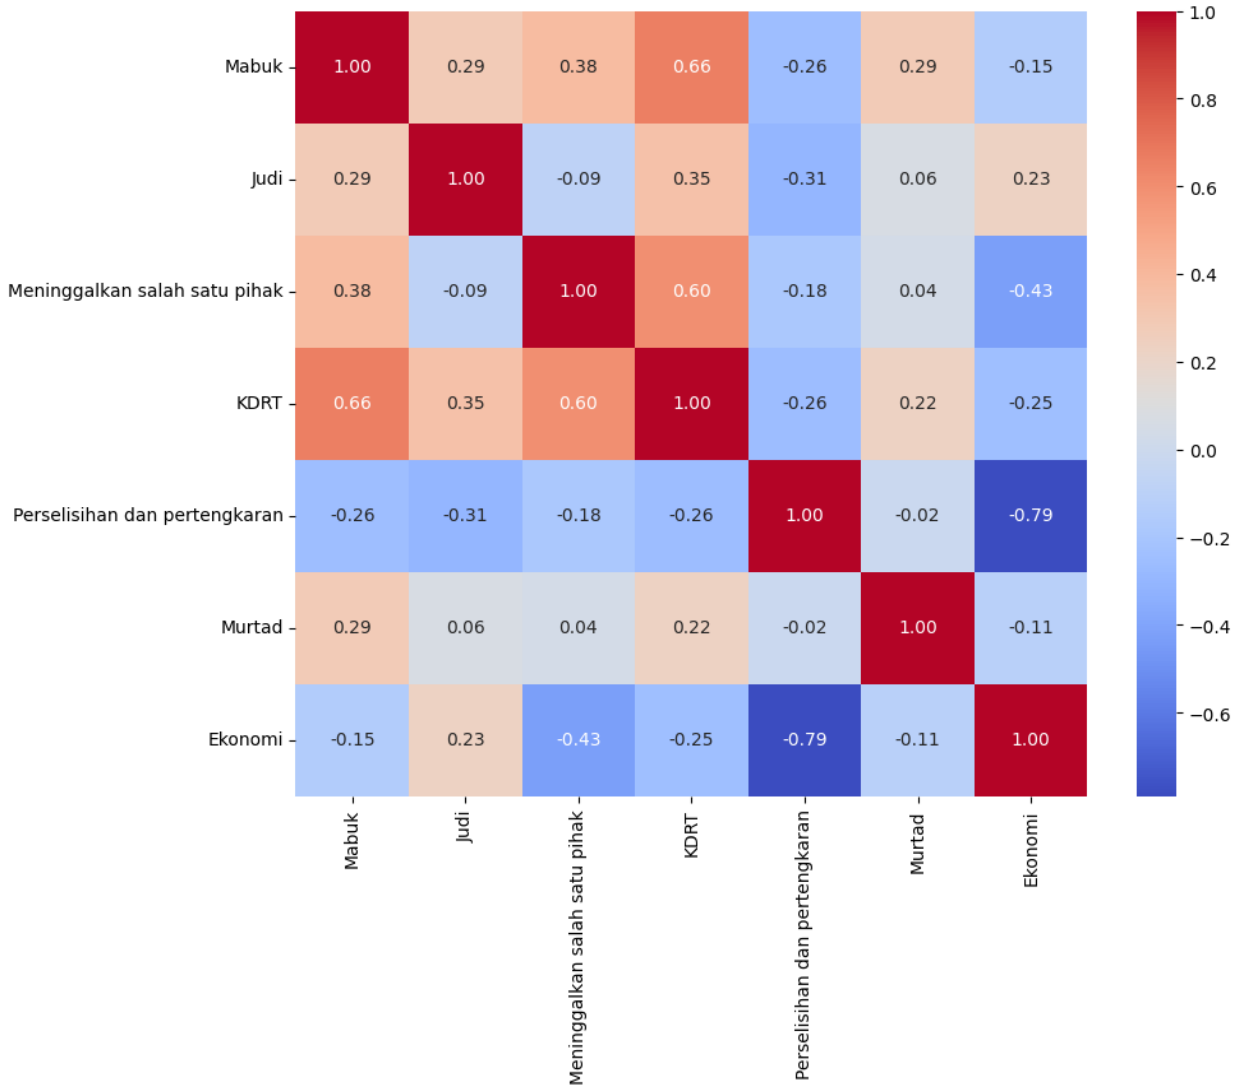
Gambar 1: Data sebelum dan sesudah diubah ke satuan persentase

Provinsi	Faktor Perceraian						
	Mabuk	Judi	Meninggalkan Salah satu Pihak	Kekerasan Dalam Rumah Tangga	Perselisihan dan Pertengkaran	Murtad	Ekonomi
Aceh	0.13%	0.42%	11.21%	1.71%	82.38%	0.20%	3.94%
Sumatera Utara	0.20%	2.03%	17.85%	2.28%	229.79%	1.22%	7.79%
Sumatera Barat	0.02%	0.05%	14.40%	0.32%	116.81%	0.30%	1.89%
...	...	...	...	...	...	...	...

Gambar 2: Data sesudah diubah ke satuan persentase

3.2. Eksplorasi Data

Eksplorasi menggunakan korelasi berguna untuk mengetahui kekuatan dan arah hubungan antar faktor penyebab perceraian berdasarkan metode Pearson. Hasil korelasi divisualisasikan dalam bentuk heatmap. Visualisasi ini memudahkan identifikasi keterkaitan antar peubah melalui gradasi warna, di mana warna merah menunjukkan korelasi positif kuat dan biru untuk korelasi negatif. Hasil heatmap dari tahap ini adalah sebagai berikut.



Gambar 3: Heatmap matriks korelasi antarfaktor penyebab perceraian

Heatmap korelasi antarfaktor perceraian menunjukkan bahwa beberapa faktor memiliki keterkaitan yang kuat satu sama lain. Korelasi tertinggi terlihat antara mabuk dan KDRT (0,66), serta KDRT dan meninggalkan salah satu pihak (0,60), yang mengindikasikan bahwa kekerasan dalam rumah tangga sering terjadi bersamaan dengan kebiasaan mabuk dan tindakan meninggalkan pasangan. Selain itu, judi juga berkorelasi positif dengan KDRT (0,35), mendukung hubungan antara perilaku adiktif dan kekerasan. Sebaliknya, korelasi negatif paling kuat ditemukan antara perselisihan dan pertengkaran dan ekonomi (-0,79), yang menunjukkan bahwa ketika masalah ekonomi menjadi penyebab perceraian, konflik rumah tangga seperti pertengkaran cenderung tidak dominan, atau sebaliknya. Korelasi-korelasi ini penting untuk mengidentifikasi kelompok faktor yang saling berkaitan dan dapat dianalisis lebih lanjut melalui teknik *clustering*.

3.3. Matriks Afinitas

Setelah proses eksplorasi awal, langkah selanjutnya adalah membentuk matriks afinitas sebagai dasar dalam metode *spectral clustering*. Matriks ini merepresentasikan tingkat kedekatan atau kemiripan antar data berdasarkan seluruh faktor penyebab perceraian. Pembentukan matriks dilakukan menggunakan fungsi Gaussian kernel (juga dikenal sebagai *radial basis function*). Dalam fungsi ini, parameter gamma diatur sebesar 0,5 untuk mengontrol seberapa jauh pengaruh satu titik data terhadap yang lainnya. Semakin besar nilai gamma, semakin lokal pengaruh kedekatan antar data. Output dari proses ini berupa matriks simetris yang menunjukkan nilai kemiripan antar provinsi, di mana nilai yang lebih tinggi menandakan bahwa dua provinsi memiliki profil faktor perceraian yang lebih mirip. Berikut ini adalah matriks afinitas yang dihasilkan.

$$A = \begin{bmatrix} 1{,}000000 & \dots & 0{,}998195 \\ 0{,}997385 & \cdots & 0{,}991761 \\ \vdots & \ddots & \vdots \\ 0{,}998195 & \dots & 1{,}000000 \end{bmatrix}$$

3.4. Matriks Derajat

Matriks derajat (degree matrix) merupakan bagian penting dalam konstruksi laplacian pada metode *spectral clustering*. Matriks derajat dibentuk dengan menjumlahkan seluruh nilai pada setiap baris dalam matriks afinitas yang merepresentasikan total kedekatan satu provinsi terhadap semua provinsi lainnya. Hasilnya adalah matriks derajat berukuran sama dengan jumlah observasi, di mana setiap elemen diagonalnya mencerminkan total hubungan (atau bobot afinitas) dari masing-masing provinsi. Matriks ini menjadi komponen penting dalam pembentukan matriks laplacian yang akan digunakan untuk mengekstraksi informasi spektral dalam proses klasterisasi. Berikut ini matriks derajat yang dihasilkan.

$$D = \begin{bmatrix} 33{,}406 & \dots & 0 \\ 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & 0 & 33{,}465 \end{bmatrix}$$

3.5. Matriks Laplacian Simetris Normalisasi

Matriks Laplacian simetris dihitung menggunakan matriks afinitas dan derajat yang telah dibentuk sebelumnya menggunakan metode normalisasi. Fungsi dari matriks tersebut adalah menggambarkan hubungan antar provinsi dimana setiap provinsi diperlakukan secara adil dalam perhitungan kemiripan. Matriks Laplacian simetris yang diperoleh adalah sebagai berikut.

$$L_{sym} = \begin{bmatrix} 0{,}9700656 & \cdots & -0{,}0298543 \\ -0{,}0299715 & \cdots & -0{,}0298339 \\ \vdots & \ddots & \vdots \\ -0{,}0298543 & \cdots & 0{,}97011776 \end{bmatrix}$$

3.6. Dekomposisi Eigen

Dekomposisi eigen dilakukan pada matriks L_{sym} untuk memperoleh tiga eigenvektor utama. Ketiga eigenvektor tersebut merepresentasikan data baru dalam ruang tiga dimensi yang memudahkan proses pengelompokan provinsi berdasarkan kemiripan pola faktor perceraian. Jumlah kluster optimal sebanyak tiga dipilih karena memudahkan interpretasi hasil serta cukup mewakili variasi utama antar provinsi. Berikut hasil dari matriks eigenvektor yang diperoleh.

$$X = \begin{bmatrix} -0{,}1722726 & -0{,}1042735 & -0{,}0652386 \\ -0{,}17160920 & -0{,}1515342 & -0{,}0201594 \\ \vdots & \ddots & \vdots \\ -0{,}17242276 & -0{,}0783293 & 0{,}0570118 \end{bmatrix}$$

3.7. Normalisasi Baris Matriks Eigenvektor

Setiap baris matriks X dinormalisasi sehingga memiliki panjang vektor yang sama agar jarak antar provinsi dalam ruang fitur baru menjadi seimbang. Tujuannya adalah mengurangi efek perbedaan skala antar provinsi dan membantu algoritma *K-Means* dalam mengelompokkan data menjadi lebih akurat. Hasil normalisasi ini ditunjukkan dalam matriks berikut.

$$Y = \begin{bmatrix} -0{,}8138490 & -0{,}4926082 & -0{,}3081997 \\ -0{,}562571 & -0{,}4967607 & -0{,}0201594 \\ \vdots & \ddots & \vdots \\ -0{,}8718074 & -0{,}3960500 & 0{,}2882644 \end{bmatrix}$$

3.8. Clustering

Berdasarkan hasil analisis *spectral clustering* menggunakan metode *K-Means*, diperoleh dua kelompok provinsi yang memiliki karakteristik berbeda dalam hal faktor-faktor penyebab perceraian, yaitu mabuk, judi, meninggalkan salah satu pihak, perselisihan dan pertengkaran, kekerasan dalam rumah tangga (KDRT), murtad, serta ekonomi. Hasil analisis lanjutan terhadap rata-rata proporsi penyebab perceraian pada setiap klaster ditemukan bahwa dua dari tiga klaster yang terbentuk memiliki pola distribusi yang serupa dengan dominasi homogen oleh faktor perselisihan dan pertengkaran. Hal ini mengindikasikan bahwa klaster tersebut tidak memiliki karakteristik pembeda yang signifikan sehingga tidak menawarkan nilai tambah secara analitis maupun kebijakan. Maka dari itu, analisis akhir dilakukan dengan menggunakan dua klaster berdasarkan pada hasil yang lebih representatif secara substansi dan interpretasi untuk menjelaskan faktor-faktor penyebab perceraian sesuai yang tertera pada Tabel 2. Hal ini sesuai dengan penelitian yang telah dilakukan oleh Kodinariya dan Makwana (2013) yang menyatakan bahwa meskipun hasil evaluasi kuantitatif menggunakan *Silhouette Score* menunjukkan bahwa tiga klaster adalah jumlah yang optimal secara teknis tetapi pendekatan ini tidak menjamin interpretasi yang bermakna secara substantif. Jain (2010) juga menegaskan bahwa evaluasi klaster tidak hanya

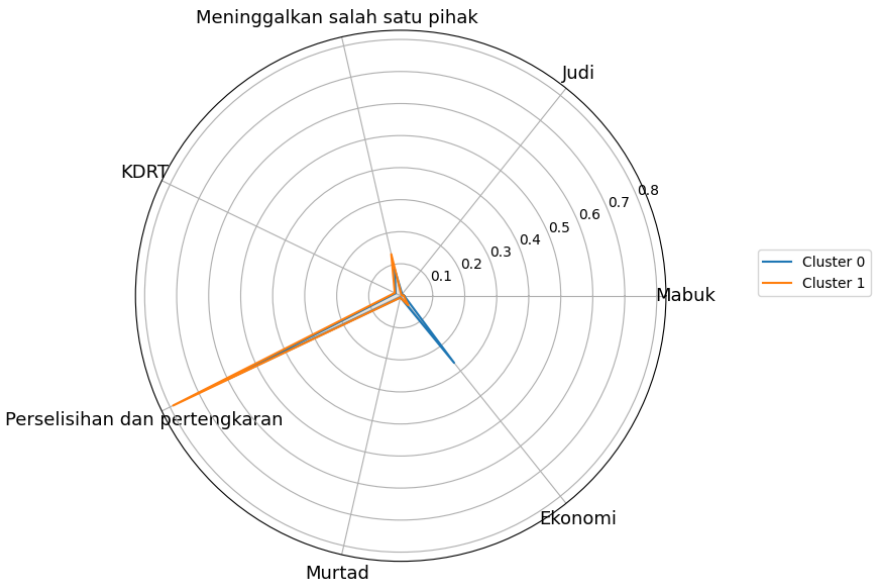
bergantung pada metrik internal seperti *Silhouette Score* tetapi juga pada kemampuannya merepresentasikan struktur kelompok yang bermakna dan interpretatif dalam domain kajian.

Tabel 2: Karakteristik hasil klastering

Labels	**0**	**1**
Mabuk	0,01%	0,01%
Judi	0,01%	0,00%
Meninggalkan salah satu pihak	0,09%	0,13%
KDRT	0,02%	0,02%
Perselisihan dan pertengkaran	0,61%	0,79%
Murtad	0,01%	0,01%
Ekonomi	0,27%	0,04%

Berdasarkan informasi pada Tabel 2, kedua klaster sama-sama memiliki rataan yang tinggi pada faktor perselisihan dan pertengkaran. Hal ini menunjukkan bahwa konflik perselisihan dan pertengkaran merupakan faktor utama penyebab terjadinya perceraian hampir di seluruh wilayah di Indonesia. Klaster pertama (Cluster 0) terdiri dari provinsi dengan nilai rata-rata lebih tinggi pada faktor ekonomi sebagai penyebab perceraian kedua selain faktor perselisihan, diikuti dengan meninggalkan salah satu pihak, KDRT, dan lainnya. Klaster pertama ini terdiri atas provinsi Lampung, Kepulauan Bangka Belitung, DKI Jakarta, Jawa Barat, Jawa Tengah, Jawa Timur, Banten, dan Papua Barat.

Sebaliknya, klaster kedua (Cluster 1) mencerminkan provinsi-provinsi dengan tingkat permasalahan sosial yang utama, yaitu faktor meninggalkan salah satu pihak dengan nilai rata-rata tertinggi kedua. Klaster kedua ini terdiri atas provinsi Aceh, Sumatera Utara, Sumatera Barat, Riau, Jambi, Sumatera Selatan, Bengkulu, Kepulauan Riau, DI Yogyakarta, Bali, Nusa Tenggara Barat, Nusa Tenggara Timur, Kalimantan Barat, Kalimantan Tengah, Kalimantan Selatan, Kalimantan Timur, Kalimantan Utara, Sulawesi Utara, Sulawesi Tengah, Sulawesi Selatan, Sulawesi Tenggara, Gorontalo, Sulawesi Barat, Maluku, Maluku Utara, dan Papua.



Gambar 4: Radar plot hasil *clustering* antarfaktor penyebab perceraian

Visualisasi radar plot yang tertera pada Gambar 4 turut memperkuat keputusan hasil analisis dengan memperlihatkan kontras yang lebih jelas antara dua klaster dalam dimensi faktor penyebab perceraian di Indonesia. Klaster pertama menunjukkan dominasi faktor ekonomi, sedangkan klaster kedua lebih dipengaruhi oleh faktor sosial seperti meninggalkan salah satu pihak dan KDRT. Kontras ini memberikan bobot interpretasi yang lebih kuat serta membuka peluang untuk perumusan kebijakan yang lebih terarah dan kontekstual. Berdasarkan pertimbangan tersebut, dua klaster dipilih sebagai penyebab perceraian antarprovinsi di Indonesia. Pendekatan ini diyakini memberikan hasil yang lebih bermakna secara kebijakan serta mampu merefleksikan kompleksitas realitas sosial secara lebih akurat.

Temuan ini menegaskan pentingnya pendekatan berbasis data dalam memahami dinamika sosial yang kompleks seperti perceraian. Oleh karena itu, direkomendasikan agar analisis segmentasi seperti ini dimanfaatkan oleh lembaga layanan sosial dan pembuat kebijakan untuk merancang intervensi yang lebih terarah dan berbasis bukti. Penggunaan metode klaster memungkinkan identifikasi kelompok populasi dengan karakteristik penyebab perceraian yang serupa sehingga strategi pencegahan dan konseling dapat disesuaikan secara lebih tepat sasaran. Selain itu, integrasi teknik ini dengan data sosiodemografis tambahan atau sistem prediksi berbasis *machine learning* dapat memperkuat akurasi pemetaan masalah dan menghasilkan kebijakan sosial yang lebih responsif. Penelitian lanjutan disarankan untuk menguji validitas hasil ini pada wilayah lain dan dengan data longitudinal guna mengevaluasi dinamika perubahan penyebab perceraian dari waktu ke waktu.

4. Simpulan dan Saran

4.1. Simpulan

Hasil analisis menggunakan *spectral clustering* dengan metode *K-Means* mampu melakukan pembentukan klaster dengan data yang bersifat non-linier serta memiliki jumlah amatan tidak terlalu banyak. Hasil analisis menunjukkan bahwa pengelompokkan faktor-faktor penyebab perceraian di Indonesia dengan dua klaster memberikan representasi yang lebih bermakna, menegaskan bahwa evaluasi klaster harus mempertimbangkan aspek substantif dan interpretatif. Faktor perselisihan dan pertengkaran merupakan faktor utama tertinggi yang menyebabkan perceraian hampir di seluruh wilayah Indonesia diikuti dengan faktor pendukung yang berbeda antara dua klister, yaitu faktor ekonomi pada klaster pertama dan faktor sosial pada klaster kedua.

4.2. Saran

Penelitian selanjutnya disarankan untuk menambahkan peubah-peubah tambahan yang lebih beragam, seperti tingkat pendidikan, status pekerjaan, faktor budaya, dan lainnya. Penambahan peubah ini diharapkan dapat memberikan pemahaman yang lebih komprehensif mengenai penyebab perceraian di berbagai provinsi di Indonesia. Selain itu, penggunaan metode analisis alternatif seperti DBSCAN, pendekatan berbasis model seperti Gaussian Mixture Models dapat dilakukan untuk membandingkan hasil klaster dan menemukan struktur segmentasi yang mungkin lebih akurat atau informatif. Dengan demikian, hasil analisis yang diperoleh akan semakin relevan secara empiris dan mampu menjadi landasan yang lebih kuat bagi penyusunan kebijakan sosial yang responsif dan berbasis bukti.

Daftar Pustaka

Amato, P. R., & Patterson, J. (2017). The intergenerational transmission of Union Instability in Early Adulthood. *Journal of Marriage and Family*, *79*(5), 1269-1286.

Cherlin, A. J. (2020). *Labor's Love Lost: Work, Intimacy, and the Social Production of Personal Life*. Russell Sage Foundation.

Gottman, J. M., & Silver, N. (2015). *The seven principles for making marriage work: A practical guide from the country's foremost relationship expert*. Harmony Books.emery.

Kodinariya, T. M., & Makwana, P. R. (2013). Review on determining number of cluster in K-Means clustering. *International Journal of Advance Research in Computer Science and Management Studies, 1*(6), 90–95.

Marple, L. (2019). Digital Spectral Analysis (2nd ed.). Dover Publications. Retrieved from https://www.perlego.com/book/955191/digital-spectral-analysis-second-edition-pdf (Original work published 2019).

Moumen, A., Shafqat, A., Alraqad, T., Alshawarbeh, E. S., Saber, H., & Shafqat, R. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. *Scientific Reports, 14*(1), 502. https://doi.org/10.1038/s41598-023-50839-1.

Ng AY, Jordan MI, Weiss Y. 2002. *On spectral clustering: Analysis and an algorithm*. University of California, Berkeley.

Stanley, S. M., Carlson, R. G., Rhoades, G. K., Markman, H. J., Ritchie, L. L., & Hawkins, A. J. (2020). Best Practices in Relationship Education Focused on Intimate Relationships. *Family Relations*, *69*(3), 497–519. https://doi.org/10.1111/fare.12419.

Sulistiyana, D. A. K., & Martanto. (2021). *Pembangunan Model Clustering dalam Pengelompokan Pengadilan Agama Berdasarkan Kasus Perceraian dengan Menggunakan Algoritma K-Means*. KOPERTIP: Jurnal Ilmiah Manajemen Informatika dan Komputer, 5(2), 57–62.

Tan PN, Steinbach M, Kumar V. 2006. Introduction to data mining. Addison Wesley, Minnesota.

Trivedi S, Pardos ZA, Sarkozy GN, Heffernan NT. 2008. Spectral Clustering in Educational Data Mining. Worcester Polytechnic Institute, United States.

Vendramin L, Campello RJGB, Hruschka ER. 2008. A robust methodology for comparing performances of clustering validity criteria. *Lecture Notes in Artificial Intelligence*. 5249:237-247.

Weiss Y. 1999. Segmentation using eigenvectors: a unifying view. CS Division, UC Berkeley.

Zhang Z, Wu X, Yu PS. 2006. Spectral Clustering for Multi-type Relational Data. *Proceedings of the 23rd International Conference on Machine Learning*.